

Jiwoo Kum

M.S. Student
Soongsil University
School of Software

Email: rmawldn@gmail.com

Home: <https://goldi1204.github.io/>

LinkedIn: www.linkedin.com/in/jiwookum

LIFELONG RESEARCH OBJECTIVE

My lifelong research objective is to uncover the fundamental principles behind how complex phenomena emerge and operate, and to develop ways to explain and validate them, contributing to deeper understanding and practical problem-solving.

RESEARCH INTERESTS

My research interests center on LLM interpretability and the development of capable small language models. I aim to understand how knowledge and reasoning capabilities are represented and processed within large language models by analyzing their internal representations and mechanisms. Building on these insights, I investigate how such capabilities can be effectively transferred to smaller models through knowledge distillation and related techniques. Ultimately, my goal is to bridge the understanding of model internals with practical methods for improving the reasoning ability, efficiency, and overall performance of small language models.

EDUCATION

- **Soongsil University** Mar. 2027 - Aug. 2028 (Expected)
M.S. in Software (advisor: Chanjun Park)
Lab: <https://sites.google.com/view/ssu-nlp/home>
- **Soongsil University** Mar. 2021 - Feb. 2027 (Expected)
B.S. in Software (advisor: Chanjun Park)
GPA: 3.86/4.5

PUBLICATIONS

Equal contribution: *, Corresponding author: †

Google Scholar: <https://scholar.google.com/citations?user=ywx-3wgAAAAJ&hl=ko>

Conferences

1. **OMIT the Action: Measuring Framing-Invariant Omission Bias under Philosophical Disagreement**

Sihyeon Lee, Jihun Song, Chanwoo Kim, Jiwoo Kum, Chanjun Park[†]

AAACL-IJCNLP 2026 - 22Findings

Domestic Conferences

1. **KoEvoSkillBench: 자기진화형 에이전트의 스킬 주입 보안을 위한 한국어 벤치마크**

김도윤, 김찬우, 조성현, 금지우, 송은서, 송지훈, 박찬준[†]

HCLT 2026 - 우수논문

2. **한국어 상층 페르소나 지시에서의 LLM 해결 양상 분석: 동일 우선순위를 중심으로**

이시현, 금지우, 송지훈, 추교준, 김찬우, 박찬준[†]

HCLT 2026

3. **많은 정보가 더 나은 예측을 만드는가? 대규모 언어 모델의 인간 어휘 이해도 예측 분석**

송은서, 조성현, 남채린, 추교준, 금지우, 박찬준[†]

HCLT 2026

4. **다중 에이전트 토론을 활용한 언어모델의 한국어 추론 오류 진단**

금지우, 송민수, 김찬우, 이시현, 김도윤, 박찬준[†]

HCLT 2026

5. **K-Press: 한국어 벤치마크 능력 프로파일링을 위한 문항 기반 능력 축 유도**

장지윤, 조성현, 김도윤, 송지훈, 추교준, 금지우, 박찬준[†]

HCLT 2026

6. **대규모 언어 모델의 도구 호출에서의 이름 의존성 분석**

남채린, 조성현, 이시현, 금지우, 송민수, 송은서, 박찬준[†]

HCLT 2026

Research Projects

Soongsil University

- 2026년 인공지능 말뚱 운영 및 연계 행사 개최 (2026, 참여연구자 (용역과제), National Institute of the Korean Language)
- 2026년 인공지능의 한국어 능력 표준 평가 과제 구축 및 활용 (2026, 참여연구자 (용역과제), National Institute of the Korean Language)
- 우수연구 신진연구 (유형B) (2026-2029, 참여연구자 (3책5공), NRF)
- Foundation Model 운용과정에서 민감정보 추론 방지 및 리스크 평가 기술 개발 (2026-2028, 참여연구자 (3책5공), Korea Internet & Security Agency (한국인터넷진흥원))
- 토론과 소통으로 지식을 연결하는 AI 에이전트 기술 개발 (2026-2028, 참여연구자(PM) (3책5공), Korea Creative Content Agency(한국콘텐츠진흥원))
- AI 보안 특화 'AI 에이전트' 개발 선행 연구 (2026, 참여연구자 (용역과제), 한국정보보호학회 산하 AI보안연구회)
- 국가·공공기관 가이드라인 준수를 위한 AI 시스템 보안 위협 자동화 기술점검 도구 개발 (2026, 참여연구자, KIST)
- AI 연구용 컴퓨팅 지원 프로젝트 (파라미터 수준의 정보 제어 원천기술 연구 및 파라미터 스튜디오 플랫폼 개발) (2026, 참여연구자, KETI)

External Activities

Teaching Assistant

- SaRangAXConnect, AI Transformation (AX) Program (September 2026)

RESEARCH GRANTS/FELLOWSHIPS

Research Grants

- VESSL AI GPU Grant Program (2026)

PATENTS

Domestic Patent Applications

- 비평 이력 기반 추론 정제 방법 및 장치
박찬준, 금지우
Korean Patent Application, filed on July 31, 2026 (Application No. 10-2026-0142423).